Séance 3

Un corpus se construit

Population → critères → métadonnées → regard sur le HTML

Décider quoi collecter avant de collecter,
et apprendre à lire sous la page.

Francis Lareau • Troisième séance

La chaîne de l’enquête : nous sommes à l’étape de conception du corpus

Question et cadre	**Corpus**	Acquisition	Préparation	Analyse	Discussion

Étape b : quelles données, quelles unités et quelles comparaisons permettent de répondre à la question ?

Trace attendue : un plan de corpus et des critères explicites.

Jalon de la séance 3 : un plan de corpus et des critères explicites.

Trois objectifs pour deux heures

1. Décider

Définir la population, les critères et les métadonnées utiles.

2. Comprendre

Découvrir comment est construite une page HTML.

3. Observer

Inspecter des pages et repérer ce qui est caché.

Les décisions de corpus s’appuient sur ce que les pages contiennent vraiment.

Où en êtes-vous dans votre dossier ?

Question	question_recherche.md, avec sous-questions et hors périmètre
Cadre	Concepts définis, opérationnalisation, bibliographie
Exemples	Cinq exemples réellement lus, dont un cas ambigu
Carnet	demarrage.ipynb exécuté ou erreur notée

Une question encore instable est normale : nous la réviserons avec le corpus.

Un corpus n’est pas une collection de textes

C’est un échantillon construit pour rendre une question observable.

Ne pas partir de ce qui est disponible, mais de ce que la question exige.

De la population visée au corpus final

Population visée → **Documents repérés** → **Documents éligibles** → **Corpus pilote** → **Corpus final**

À chaque étape, des documents sont perdus : inaccessibles, hors critères, incomplets.

Le pilote et le corpus final sont l'objet des séances suivantes.

Population visée ≠ documents accessibles ≠ corpus effectivement observé.

Population visée et corpus effectivement visé

Population visée

Tous les articles de la revue sur toute sa période.

Corpus visé

Articles de recherche dont le texte et les métadonnées sont accessibles.

Genre, langue, période, source, unité documentaire, unité d’analyse.

Inclure, exclure : des règles qui se justifient

CRITÈRE	RÈGLE	JUSTIFICATION
Source	Publié dans la revue retenue	Population délimitée
Genre	Article de recherche	Lien avec la question
Texte	Texte intégral exploitable	Condition d’analyse
Doute	Statut « à vérifier »	Décision documentée

Chaque règle porte sa justification. Les cas limites vont dans le journal.

Échantillonnage et métadonnées : l’essentiel d’abord

Plan d’échantillonnage

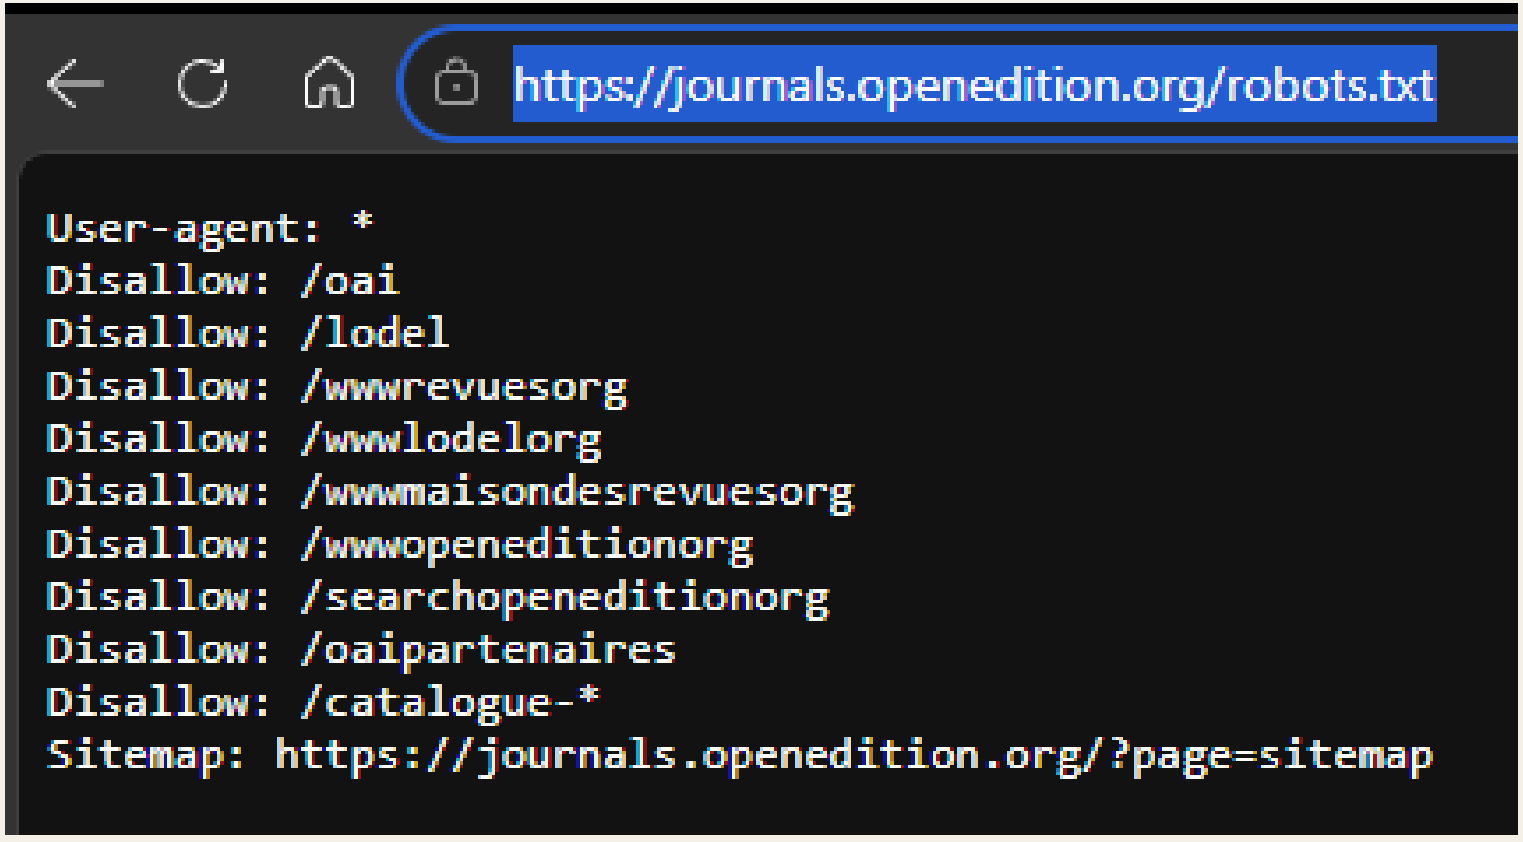
Population complète : quelques phrases suffisent. Sinon, indiquer comment les documents sont choisis.

Plan des métadonnées

Identifiant, adresse, titre, numéro ou date, langue, type, statut. Seulement ce que vous saurez extraire.

La liste de départ sera complétée plus tard, avec ce que vous aurez observé.

Évaluation de la faisabilité en fonction des interdictions



Ouvrir le robots.txt d’OpenEdition Journals

Évaluation de la faisabilité en fonction des Conditions Générales d'Utilisation

Ouvrir le document CGU utilisateur

Accès et collecte

Qui peut accéder ?

Quelle automatisation ?

Quels quotas ou restrictions ?

Réutilisation

Que peut-on conserver ?

Partager ou redistribuer ?

Transmettre à service externe ?

Élément	Moissonner/collecter	Analyser	Rediffuser dans GitHub/dataset
Métadonnées	✅	✅	✅ CC0
Texte pour TDM	✅ dans le cadre indiqué par les CGU	✅	⚠️ dépend de la licence de l'article
Texte CC BY	✅	✅	✅ selon CC BY
Texte CC BY-NC	✅	✅	✅ sous conditions de CC BY-NC
Texte « Tous droits réservés »	TDM prévu par les CGU pour le contenu accessible licitement	✅ dans ce cadre	❌ pas de republication générale sans autorisation/exception applicable
Images/annexes	⚠️ droits séparés	⚠️	⚠️ vérifier individuellement

Écrire le plan de votre corpus

1. Rappeler	Copier votre question dans plan_corpus.md
2. Définir	Population, corpus visé, genre, langue, période
3. Décider	Critères d’inclusion, d’exclusion, cas limites
4. Échanger	Chercher ce qui reste flou

Fichiers : plan_corpus.md et criteres_inclusion_exclusion.md dans VS Code.

Pause de cinq minutes

Ensuite : regarder sous la page.

Ouvrez votre source dans un navigateur (Chrome, Firefox, Edge ou Safari).

Ce qu’on voit n’est pas tout ce qu’il y a

Le navigateur affiche une mise en forme.
Le code contient aussi des informations que l’écran ne montre pas.

Une date, une langue, l’adresse d’un PDF : parfois seulement dans le code.

Le HTML en quelques minutes

```
<p class="resume" lang="fr">Texte affiché à l’écran</p>
```

Balise

 ouvre,

 ferme.

Elle dit ce qu’est le contenu.

Attributs

class, lang :

des étiquettes ajoutées

dans la balise ouvrante.

Contenu

Ce qui est entre

les deux balises

et s’affiche.

Une balise nomme, un attribut précise, un contenu s’affiche.

Une page : une tête et un corps

<head> — jamais affiché

```
<title>Titre de la page</title>
<meta name="auteur"
      content="Nom Prénom">
<meta name="date"
      content="2020-05-01">
```

Métadonnées, titre de l'onglet, liens techniques.

<body> — ce qu'on lit

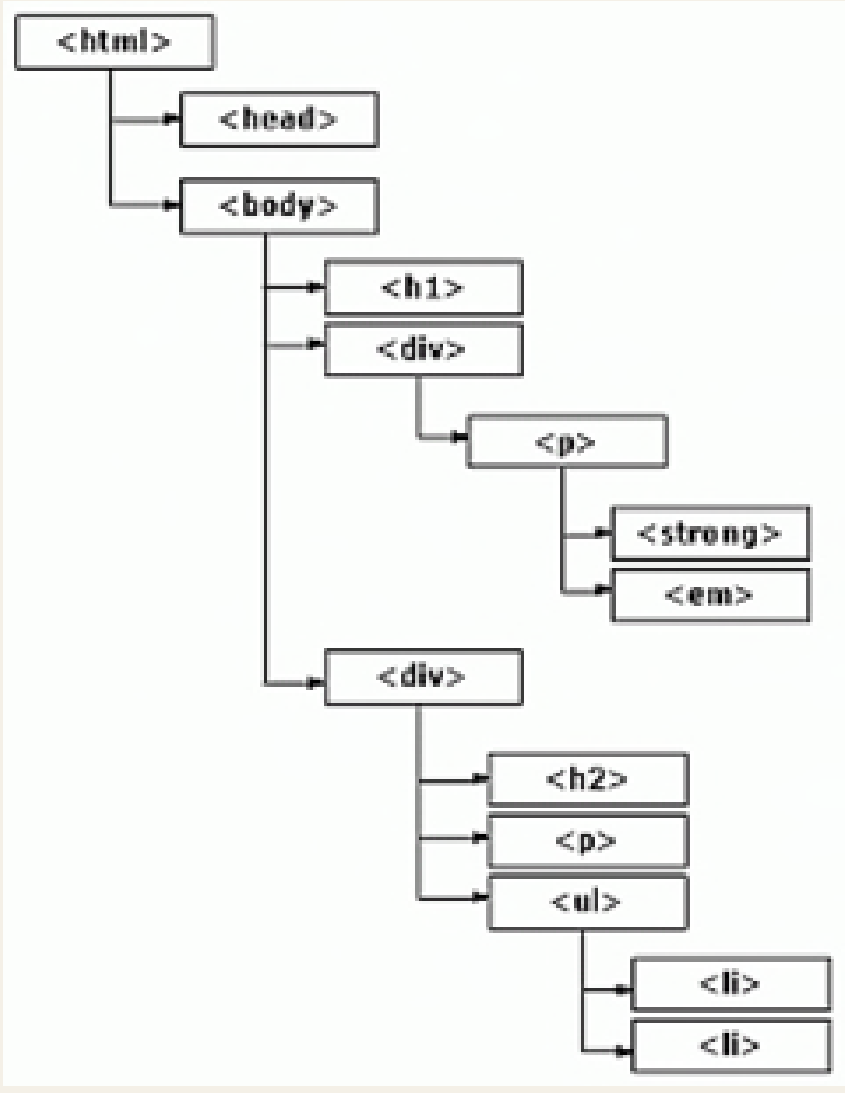
```
<h1>Titre de l'article</h1>
<p>Premier paragraphe…</p>
<a href="doc.pdf">PDF</a>
<ul><li>Élément</li></ul>
```

Titres, paragraphes, liens, listes, tableaux.

Exemples génériques : les noms de balises meta varient d'un site à l'autre.

HTML: une arborescence

- Un document HTML possède une structure hiérarchique.
- Cette structure ressemble à un arbre (*document tree*).
- Chaque élément peut être relié à d'autres éléments.
- Parent : élément situé directement au-dessus.
- Enfant (*child*) : élément directement contenu dans un parent.
- Frères et sœurs (*siblings*) : éléments ayant le même parent.
- Ces relations permettent de comprendre l'organisation et l'imbrication des éléments HTML.



Les attributs qui révèlent la structure

class, id	Rôle d’une zone : titre, résumé, texte, notes, menu
lang	Langue d’un passage ou de toute la page
href	Adresse d’un lien : page, numéro, article, PDF
content	Valeur d’une métadonnée dans une balise meta
data-…	Informations ajoutées par le site, souvent masquées

Les repères que vous noterez serviront à extraire automatiquement les informations.

Balises à reconnaître

<h1> à <h3>	Titre et intertitres
<p>	Paragraphe de texte
<a href="...">	Lien vers une page ou un fichier
** **	Liste (numéros, articles, éléments)
<meta ...>	Information sur le document, non affichée
** **	Blocs génériques, identifiés par class ou id

Vous n’avez pas besoin de tout connaître : savoir lire suffit.

Voir le code avec le navigateur

1. Ouvrir	Clic droit sur la page > Inspecter, ou F12 (macOS : Cmd + Option + I)
2. Survoler	Les lignes du code surlignent leur partie de la page
3. Chercher	Ctrl + F dans l'inspecteur : un mot vu à l'écran
4. Comparer	Ctrl + U : code source tel que le serveur l'envoie
5. Noter	Balise, attribut et zone où se trouve chaque information

Inspecter ne modifie pas le site : seulement l'affichage local, jusqu'au rechargement.

Visible à l’écran, présent dans le code ?

INFORMATION	À L’ÉCRAN ?	DANS LE CODE ?	OÙ ? (BALISE, ATTRIBUT)
Titre	?	?	?
Date	?	?	?
Langue	?	?	?
Adresse du PDF	?	?	?
Mots-clés	?	?	?

Chaque ligne remplie devient un champ possible de votre plan de métadonnées.

Inspecter cinq pages de natures différentes

Quelles pages ?

Page principale, numéro, article typique, article avec PDF, document atypique.

Que noter ?

Informations cachées, zones à exclure, différences entre les pages.

Pas de collecte automatique : observation manuelle, notes de repères seulement.

Ce que vous remettez avant la séance 4

Plan de corpus	plan_corpus.md avec population, corpus visé, taille estimée
Règles	Critères d'inclusion et d'exclusion, protocole de sélection
Sources	sources_candidates.csv avec une source retenue et une source écartée
Simples	plan_echantillonnage.md et plan_metadonnees.md (liste de départ)
Inspection	Tableau d'au moins cinq pages, informations cachées
Dépôt	Commit, push et une entrée au journal

Échéance : à préciser. Le pilote et la faisabilité viendront avec les démonstrations.