Séance 4

Du plan aux fichiers sources

Comprendre le code en le faisant fonctionner.

D’abord un pilote, puis le corpus prévu.

Support principal : le notebook de moissonnage du professeur.

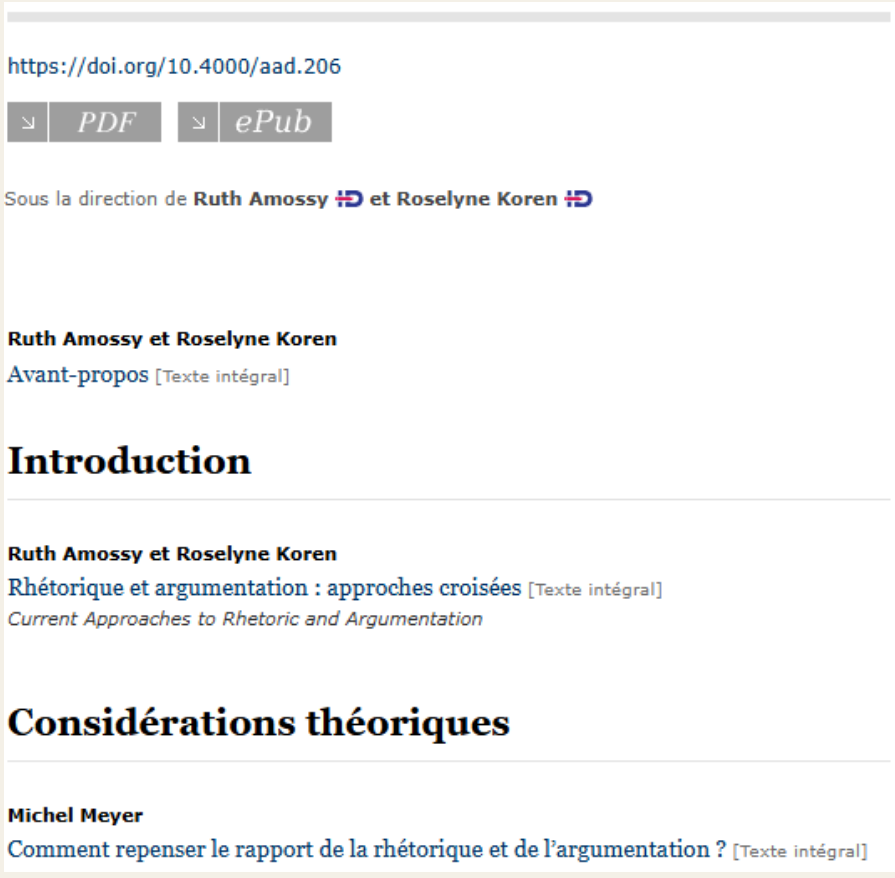
La chaîne de l’enquête : nous sommes à l’étape d’acquisition du corpus

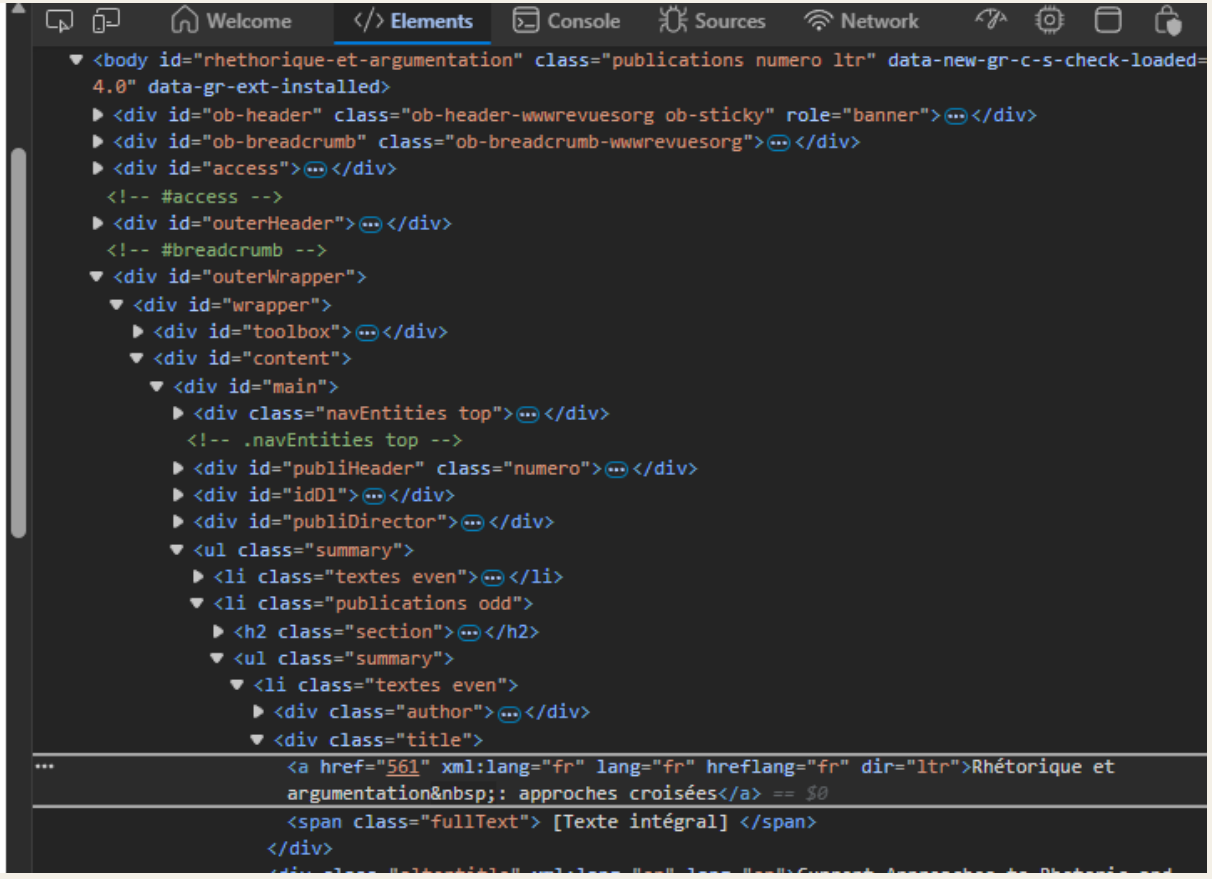
Question et cadre	Corpus	**Acquisition**	Préparation	Analyse	Discussion

Étape c : par quel moyen d’acquisition ?

Trace attendue : le corpus (inventaire et documents), une vérification.

Une balise, des attributs, un lien à retrouver





Inspecter → repérer le href → construire l'adresse complète.

Des noms pour conserver et transformer des valeurs

```
article_url = "adresse_1"
article_urls = [article_url, "adresse_2"]
response = session.get(article_urls[0])
contenu = response.content
```

= affecte une valeur / [0] prend le premier élément / . accède à un attribut ou une méthode

Lire : quelle entrée ? quelle opération ? quelle sortie ?

Imports, fonctions et paramètres

```
import pandas as pd
from pathlib import Path
from urllib.parse import urljoin
```

requests : requêtes / lxml : HTML / pandas : tableaux / pathlib : chemins

Une fonction nomme une opération ; ses arguments précisent sur quoi elle agit.

Les blocs sont définis par l’indentation

```
for article_url in article_urls:
    if article_url:
        try:
            response = polite_get(article_url)
        except Exception as error:
            print(error)
```

for répète / if choisit / try–except traite une erreur prévue.

Prévoir → exécuter → vérifier

1. Qu’est-ce que cette cellule utilise ?
2. Que fait-elle ?
3. Que doit-elle produire ?
4. Quel résultat avons-nous réellement obtenu ?

Langues_de_specialite/chaine/03_acquisition/exemple/Moissonnage_exemple_colab.ipynb

Le pilote est-il concluant ?

Repérage	Comparer les liens au sommaire
Fichiers	Présents, non vides, bons formats et bons documents
Provenance	Relier ID, source, URL, fichier et date
Critères	Distinguer récupéré, retenu et à vérifier
Reprise	Sauvegarder et éviter doublons ou retéléchargements

Si une erreur bloque l’objectif : corriger, retester, puis décider.

Passer au corpus complet sans changer les précautions

1. Justifier	Documenter la décision et la version testée
2. Étendre	Parcourir tous les numéros prévus par le plan
3. Réutiliser	Garder les fichiers valides du pilote, sans doublons
4. Sauvegarder	Collecter par blocs et reprendre ce qui manque
5. Contrôler	Comparer couverture prévue et couverture obtenue

Corpus complet = périmètre du plan, pas tout le site.

Adapter le premier parcours à votre propre source

Vérifier

Conditions, pages visées, chemins et paramètres.

Adapter

URL et repères HTML.

Un numéro ou un ensemble pilote.

Expliquer

Entrées, opération, sorties.

Un contrôle à réaliser.

Objectif en classe : un premier test maîtrisé, pas une course au volume.

Quatre traces, quatre fonctions distinctes

Protocole et code	Comment réaliser et reprendre la collecte ?
Inventaire	Quels documents et fichiers avons-nous obtenus ?
Log automatique	Quelles opérations ou erreurs se sont produites ?
Contrôle	Qu’avons-nous vérifié ?
Journal	Pourquoi avons-nous décidé ceci ou cela?

o

Vérifier → piloter → étendre → contrôler

Accès	Vérifications datées dans acces_sources.csv
Code personnel	Inspiré au besoin du notebook de démonstration
Pilote	Un numéro ou un ensemble justifié, contrôlé
Collecte	Tout le corpus défini après un pilote concluant
Bilan	Inventaire, contrôle, limites et décisions de journal

Si la collecte reste bloquée : expliquer le manque et la suite, sans le masquer.