SYLLABUS

Langues de spécialité

Concevoir et conduire une enquête

22 heures, 11 séances

1. Cadre

Élément	Proposition
Intitulé	Langues de spécialité
Format	11 séances de 2 heures, soit 22 heures encadrées
Travail personnel indicatif	Environ 3 à 4 heures par semaine
Organisation	Projet individuel ou en équipe, sous réserve de validation

Description du cours

Ce cours forme à la conception et à la réalisation d'une enquête empirique sur les langues et discours de spécialité. Les étudiants formulent une question de recherche, conçoivent un corpus adapté, acquièrent les données, les préparent et les représentent selon leurs besoins, choisissent une méthode d'analyse, puis interprètent et discutent les résultats. Le parcours articule lecture des textes, traitements informatiques et réflexion sur les décisions qui rendent les phénomènes observables.

La terminologie et l'analyse conceptuelle constituent des axes possibles, et non la destination obligatoire du cours. Les projets peuvent aussi porter sur la phraséologie, la grammaire, les genres, le positionnement énonciatif, l'argumentation, les citations, les thèmes ou la médiation des savoirs. Chaque projet doit expliciter son apport à la compréhension des usages d'un domaine, d'une communauté ou d'une situation de communication spécialisée.

Compétence intégratrice

Concevoir, documenter et défendre une enquête sur un phénomène de langue de spécialité en justifiant l'adéquation entre la question, le corpus, les transformations des données, les méthodes et les conclusions.

Objectifs d'apprentissage

- Formuler une question pertinente, délimitée, empiriquement étudiable et faisable dans le cadre du semestre.
- Mobiliser un cadre conceptuel et traduire les notions étudiées en unités, catégories ou indicateurs observables.
- Concevoir et acquérir un corpus traçable, en justifiant les critères de sélection et les comparaisons.
- Préparer les données sans perdre les informations nécessaires à l'enquête, et contrôler les transformations.
- Choisir et mettre en œuvre une analyse adaptée, puis vérifier la qualité et la sensibilité de ses résultats.
- Interpréter les observations, examiner les explications concurrentes et délimiter la portée des conclusions.
- Produire a) un journal réflexif, b) un dépôt documenté et c) un texte scientifique structuré IMRAD (Introduction, Méthode, Résultats et Discussion).

Prérequis et préparation

Sont attendues une capacité de lecture scientifique et une connaissance élémentaire des fichiers, tableaux de données et scripts en Python ou en R. Une préparation technique guidée sera proposée. Le cours ne suppose pas une maîtrise avancée du TAL ou de l'apprentissage automatique. Un seul langage principal sera retenu pour les démonstrations et annoncé avant le semestre ; les protocoles manuels et les logiciels à interface graphique restent admissibles lorsqu'ils sont adaptés au projet.

2. Organisation et progression

Démarche pédagogique

Le cours combine apports conceptuels, lecture critique d'études, démonstrations, ateliers accompagnés et relectures entre pairs. Un corpus commun et des fichiers locaux de secours permettent de poursuivre les apprentissages en cas de problème d'installation ou d'accès aux sources. Les outils sont choisis après définition de la question : toutes les équipes ne doivent pas réaliser toutes les opérations techniques.

La chaîne de référence est : question et cadre conceptuel → conception du corpus → acquisition → préparation et représentation → analyse et validation → interprétation et discussion. Elle est itérative : un pilote ou une erreur peut conduire à réviser un choix antérieur. Les révisions sont datées et justifiées ; elles ne doivent pas être effacées du récit de recherche lorsqu'elles affectent la lecture des résultats.

Étapes du projet

Étape	Décision centrale	Trace attendue
a. Question	Quel phénomène de langue de spécialité étudier et avec quel cadre conceptuel ?	Question, premiers exemples et courte revue des travaux pertinents
b. Corpus	Quelles données, unités et comparaisons permettent de répondre à la question de recherche ?	Plan de corpus, critères d'inclusion/exclusion
c. Acquisition	Quelle voie d'accès convient et comment vérifier la collecte ?	Inventaire, procédure, conditions d'accès et journal de collecte
d. Préparation	Quelles transformations et représentations sont nécessaires ?	Code ou protocole, versions des données et contrôles
e. Analyse	Quelle méthode produit des observations pertinentes et contrôlées ?	Paramètres, résultats et dossier de validation
f. Discussion	Que permettent de soutenir ces observations ?	Interprétation, limites, réponse et perspectives

Périmètre du projet

Le sujet et le plan de corpus sont validés après un pilote. Aucune taille universelle de corpus n'est imposée : volume, diversité et granularité sont justifiés selon la question et les ressources. Le projet comporte au minimum une acquisition effective, une préparation documentée, une analyse substantielle et un contrôle de qualité. Une collecte manuelle, un export ou l'acquisition d'un corpus existant peuvent convenir ; le moissonnage n'est pas obligatoire. La lemmatisation, l'analyse syntaxique, la vectorisation et la construction d'ontologies sont conditionnelles aux besoins.

Les méthodes peuvent être qualitatives, quantitatives ou mixtes. Une preuve de concept ou un projet exploratoire est admissible s'il est annoncé comme tel. Une analyse confirmatoire distingue les hypothèses formulées avant examen des résultats des explorations ultérieures. Un résultat négatif, incertain ou non significatif n'est pas pénalisé lorsqu'il est correctement établi et discuté.

Calendrier indicatif

Séance	Contenus et activité principale	Jalon du projet
1	**Langues de spécialité**, enquête scientifique, distinction objet/question/méthode.	Ouverture du dépôt et du journal
2	**Question et cadre** : problématisation, cadre conceptuel, question et faisabilité.	Développer une question initiale
3	**Conception du corpus** : sources, échantillonnage, métadonnées et unités d'observation.	Plan de corpus et critères explicites
4	**Acquisition** : corpus existant, API, moissonnage, conditions d'utilisation.	Faisabilité
5	**Extraction** HTML/ PDF, données et métadonnées, identifiants et provenance.	Échantillon et audit
6	**Nettoyage**, doublons, encodage et erreurs d'extraction.	Corpus préparé, bilan intermédiaire

Séance	Contenus et activité principale	Jalon du projet
7	**Représentations** adaptées : formes, lemmes, n-grammes, TF-IDF, plongements.	Choix de représentation justifié
8	**Analyses** (selon la question) : concordances, comparaison, annotation, regroupement ou prédiction.	Premiers résultats et méthode stabilisée
9	**Validation** : erreurs, contre-exemples, sensibilité.	Reproduction ou vérification croisée d'un résultat
10	**Interprétation** : résultats et discussion, explications concurrentes, rédaction IMRAD et relecture.	Version presque finale de l'article et du dépôt
11	**Présentation de l'enquête** : questions méthodologiques et bilan réflexif.	Dépôt final, article et journal

Les jalons des séances 2 à 11 donnent lieu à des rétroactions formatives, sans notes supplémentaires. La présentation finale est formative et sert à vérifier la compréhension individuelle; elle ne constitue pas un quatrième livrable noté. Sa durée et son organisation seront adaptées aux effectifs.

3. Consignes des trois livrables

A. Journal de bord — 20 %

Le journal rend compte de la recherche en train de se faire. Il documente les hésitations, décisions, difficultés, vérifications et révisions. Il ne constitue ni un relevé horaire ni une copie des messages de commit. Une entrée hebdomadaire au minimum est attendue, ainsi qu'une entrée lors de chaque décision importante. La longueur reste proportionnée à l'intérêt de l'entrée ; le volume n'est pas un critère de qualité.

- Date, étape et objectif poursuivi.
- Observation ou difficulté rencontrée, appuyée sur un exemple si possible.
- Options envisagées ; décision retenue et justification.
- Vérification effectuée et résultat du contrôle.
- Conséquence sur la question, le corpus, la méthode ou la suite du travail.
- Lien vers une trace pertinente : protocole, fichier, résultat, commit ou version.

Exemple : « La suppression des notes en bas de page éliminait des informations utiles à l'analyse. Je les conserve dans un champ distinct, lié au paragraphe concerné. Dix documents ont été contrôlés. Le protocole d'extraction est révisé ; la question reste inchangée. »

Le journal se termine par un bilan réflexif individuel de 500 à 800 mots : évolution du projet, décisions les plus importantes, limites restantes et apprentissages transférables.

B. Dépôt GitHub structuré — 30 %

Le dépôt reflète la chaîne effectivement réalisée, y compris ses sous-tâches. Il contient pour chacune le code ou un protocole explicite. Une procédure manuelle ou dans un logiciel à interface graphique est recevable si les règles, réglages, requêtes et contrôles sont documentés. La complexité du code et le nombre de commits ne constituent pas des critères directs de réussite. Le dépôt peut rester privé, avec accès accordé à l'enseignant. Une solution institutionnelle équivalente peut être autorisée en cas de contrainte d'accès. L'hébergement public et le partage intégral du corpus ne sont pas nécessaires.

Arborescence indicative, à adapter

```
projet/
├── README.md
├── environnement/
├── configuration/
├── journal/
├── donnees/
│   ├── README.md
```

```
│   ├── inventaire.csv
│   └── dictionnaire_metadonnees.md
├── chaine/
│   ├── 01_question_et_cadre/
│   ├── 02_conception_du_corpus/
│   ├── 03_acquisition/
│   ├── 04_preparation/
│   │   ├── 01_extraction/
│   │   ├── 02_nettoyage/
│   │   ├── 03_segmentation/
│   │   └── 04_annotation_ou_representation/
│   ├── 05_analyse/
│   ├── 06_validation/
│   └── 07_interpretation/
├── resultats/
│   ├── tableaux/
│   ├── figures/
│   └── extraits/
├── article/
└── .gitignore
```

Les dossiers non pertinents sont retirés ou adaptés. Chaque tâche ou sous-tâche de la chaine de traitement comporte une fiche README, un protocole et/ou du code, ainsi que des contrôles lorsque nécessaires. Les dépendances et embranchements sont représentés dans le README principal : une arborescence ne suffit pas à indiquer l'ordre d'exécution.

Documentation minimale de chaque sous-tâche

Champ	Exigence
Objectif	Rôle de la sous-tâche et relation à la question
Entrées	Identifiants, versions, formats et emplacement des données
Procédure	Script ou protocole manuel ; réglages, requêtes et paramètres
Sorties	Fichiers produits, structure et signification des champs
Contrôles	Critères de qualité, échantillon vérifié, anomalies et corrections
Limites	Informations perdues, erreurs restantes et conditions de validité
Reproduction	Instructions pour exécuter, réaliser ou vérifier l'opération

Exigences transversales du dépôt

- README principal : question, aperçu du corpus, schéma de la chaîne, accès aux données, installation et ordre d'exécution.
- Environnement : versions des logiciels, dépendances et modèles, fichier d'environnement adapté au langage, graines aléatoires si pertinentes.
- Inventaire : identifiant stable, source, date de collecte, genre, langue, sous-corpus, statut de récupération, référence ou URL, conditions d'accès et version.
- Conservation d'une version source non modifiée et séparation des données sources, préparées et produites, dans un stockage autorisé.
- Traçabilité des tableaux, figures et extraits : procédure génératrice, provenance et version correspondante.
- Procédure permettant à un pair de reproduire ou de vérifier au moins un résultat central.

Les données sensibles, secrets d'accès, fichiers dont le partage n'est pas autorisé et éléments volumineux restent hors du dépôt selon un plan documenté. Le dépôt indique comment accéder aux données ou vérifier l'analyse dans les limites permises. L'absence de données publiques n'est pas pénalisée lorsqu'elle est justifiée et compensée par une documentation suffisante. Un dépôt privé ne dispense pas de ces précautions.

C. Article IMRAD — 50 %

L'article présente une enquête scientifique, et non le récit chronologique des opérations techniques. Longueur indicative : 3 000 à 4 000 mots, hors résumé, bibliographie et annexes. Le texte comprend un titre, un résumé de 150 à

200 mots, trois à cinq mots-clés, les quatre sections ci-dessous et une bibliographie. La norme bibliographique est cohérente et les sources réellement consultées sont citées.

Section	Contenu attendu
Introduction	Phénomène de langue de spécialité, intérêt de la recherche, travaux pertinents, cadre conceptuel et question ; hypothèses si appropriées.
Méthodes	État de l'art, conception, sélection et acquisition du corpus ; unités et catégories ; transformations ; méthodes et paramètres ; validation ; accès aux ressources et au dépôt.
Résultats	Observations organisées selon la question, avec tableaux, figures ou extraits pertinents ; incertitudes et résultats de contrôle nécessaires à leur lecture.
Discussion	Réponse à la question ; interprétation ; confrontation aux travaux et aux textes ; explications concurrentes ; biais et limites ; portée et perspectives.

La section Méthodes doit permettre de comprendre et d'apprécier l'enquête sans lire tout le code ; elle renvoie au dépôt pour les détails d'implémentation. Les modifications importantes de question ou de méthode sont signalées lorsque pertinentes. Les conclusions ne dépassent pas ce que le corpus et l'analyse permettent de soutenir. Les analyses qualitatives et les résultats non concluants sont pleinement admissibles.

4. Évaluation et rétroaction

Barème global

Livrable	Poids	Critères et points
Journal de bord	20 %	Justification des décisions : 8 ; réflexivité et révisions : 8 ; continuité et liens vers les traces : 4.
Dépôt structuré	30 %	Organisation et traçabilité : 8 ; code/protocoles et environnement : 16 ; reprise, contrôles et validation : 6.
Article IMRAD	50 %	Question et cadre : 10 ; adéquation et justification méthodologiques : 10 ; solidité des résultats : 10 ; discussion et portée : 15 ; clarté, citations et articulation au dépôt : 5.
Total	100 %	Trois livrables articulés autour d'une même enquête.

Une même décision peut apparaître dans les trois livrables, mais elle est évaluée sous des angles distincts : genèse et réflexion dans le journal ; mise en œuvre et traçabilité dans le dépôt ; pertinence scientifique et conséquences dans l'article. La répétition de contenu n'est pas un objectif.

Niveaux d'appréciation

Niveau	Description
Maîtrisé	Choix cohérents et justifiés ; traces vérifiables ; contrôles pertinents ; interprétation nuancée et limites explicites.
Satisfaisant	Démarche globalement cohérente ; documentation suffisante ; principaux résultats étayés ; limites essentielles reconnues.
Partiel	Justifications incomplètes, contrôles limités ou ruptures entre question, méthode et conclusions.
Insuffisant	Démarche non vérifiable, choix essentiels non justifiés ou conclusions sans appui suffisant.

Rétroactions et travail collectif

Des rétroactions sont données sur la question, la chaîne de préparation et les premiers résultats. Les étudiants peuvent réviser ces productions avant la remise définitive. La relecture croisée porte sur un résultat central et sur la clarté du lien entre observations et conclusion.

En équipe, le dépôt et l'article sont évalués collectivement ; le journal et le bilan réflexif sont évalués individuellement. Une déclaration des contributions accompagne la remise. Les échanges oraux vérifient la compréhension des choix par chacun.

Remise finale

- Journal daté et bilan réflexif individuel, avec liens accessibles ou copie adaptée pour l'évaluation.
- Accès au dépôt et référence à sa version finale ; archive figée si nécessaire pour conserver l'état évalué.
- Article au format PDF et version éditable ; déclaration des contributions et des usages d'outils d'assistance.

Les règles institutionnelles de retard, absence, rattrapage, intégrité et aménagement priment. Leurs modalités exactes et les dates de remise doivent être complétées avant diffusion.

5. Ressources et règles de travail

Supports mobilisés et statut

Ressource transmise	Place dans le cours
Preprocessing.pptx	Collecte, extraction des données et métadonnées, nettoyage, segmentation, annotation et représentation. Les exemples R, XPath et regex sont adaptés aux ateliers.

Ces supports constituent une base pédagogique, non un protocole unique à appliquer. Les documentations logicielles et les exemples techniques sont vérifiés avant usage. Les lectures scientifiques sont choisies selon le phénomène étudié; chacun mobilise plusieurs travaux pertinents et discute leur rapport à sa question.

Ressources méthodologiques complémentaires

- The Turing Way, Guide for Reproducible Research et chapitres sur le versionnement : documentation, traçabilité et travail collaboratif.
- Documentation officielle GitHub : fichiers ignorés, accès au dépôt et gestion des versions.
- Documentation de TXM, spaCy, scikit-learn ou des outils effectivement retenus : paramètres, formats et limites.
- Documents méthodologiques sur les genres, l'énonciation, la terminologie ou l'argumentation, sélectionnés selon les projets.

Données, acquisition et confidentialité

- Avant la collecte, examiner les conditions d'accès, licences et autorisations ; documenter les usages et possibilités de redistribution.
- Pour le moissonnage, privilégier les accès prévus pour l'export lorsqu'ils existent ; documenter les limitations de requêtes et les règles du site.
- Éviter les données personnelles ou sensibles pour le projet pédagogique ; toute exception requiert une validation préalable et les procédures institutionnelles applicables.
- Ne pas déposer de clés, mots de passe ou jetons d'accès.
- Séparer le code et ses conditions de réutilisation des données et de leurs propres conditions ; l'étudiant ne peut attribuer une licence à des contenus dont il ne détient pas les droits.

Intégrité et outils d'assistance

L'assistance par IA peut être utilisée pour explorer des pistes, expliquer du code, proposer des tests ou aider à la rédaction, sous réserve des règles institutionnelles. Les usages substantiels sont déclarés : outil, fonction, parties concernées et vérifications réalisées. L'étudiant demeure responsable des sources, du code, des annotations, des observations et de l'argumentation. Les références, données et résultats ne doivent jamais être inventés. Une sortie

générée n’est pas présentée comme une observation du corpus sans contrôle explicite. Le journal documente les choix et vérifications importants, sans imposer la publication d’échanges contenant des informations confidentielles. Chaque étudiant doit pouvoir expliquer les transformations et les conclusions auxquelles il contribue.

Accessibilité et faisabilité

Les besoins d’aménagement peuvent être signalés selon les procédures de l’établissement. Une voie de travail équivalente est proposée en cas de contrainte technique justifiée. Le projet vise une enquête rigoureuse et réalisable, non la multiplication des logiciels. Les corpus de secours, gabarits et exemples accompagnés permettent de maintenir les apprentissages sans masquer les limites du projet personnel.